PROYECTO FINAL

Ingeniería de Datos: Pipeline ETL, Análisis Exploratorio y Cubo Dimensional con PySpark

Asignatura: Introducción a los Sistemas Big Data — Valor de la Información

Curso 2025-2026 · Trabajo en Grupos · Defensa Oral Obligatoria

Campo	Valor
Modalidad	Grupos de 3-4 estudiantes
Lenguaje principal	Python 3.10+ (pandas, matplotlib/seaborn)
Base de datos destino	SQL de elección libre (PostgreSQL, MySQL, SQLite…)
Motor analítico	PySpark en Google Colab
Repositorio	GitHub público — enlace obligatorio en el documento
Entregable final	Documento PDF o Word con portada, índice, cuerpo
Defensa oral	Material de apoyo (vídeo/PPT) de duración inferior a 5 minutos

Índice de Contenidos

1. Introducción y Contexto del Proyecto
2. Descripción de los Orígenes de Datos
3. Diagrama de Flujo del Pipeline
4. Análisis Inicial de los Orígenes — Perfil de Calidad
5. Extracción, Transformación y Limpieza (ETL)
6. Análisis Exploratorio de Datos (EDA) Final
7. Diseño del Diagrama en Estrella (Modelo Dimensional)
8. Carga en Base de Datos SQL
9. Exportación a GitHub
10. Cuaderno PySpark en Google Colab — Cubo Dimensional
11. Estructura del Documento Entregable
12. Rúbrica de Evaluación
13. Defensa Oral y Coeficiente de Calificación
14. Uso de Inteligencia Artificial y Bibliografía

1. Introducción y Contexto del Proyecto

Este proyecto pone en práctica el ciclo de vida completo del dato, desde su captura en fuentes heterogéneas hasta su explotación analítica en un entorno de procesamiento distribuido. El alumno recorrerá todas las etapas que un ingeniero de datos ejecuta en un entorno profesional real: extracción, perfilado de calidad, limpieza, transformación, modelado dimensional, carga en base de datos relacional y análisis con PySpark.

OBJETIVO GENERAL: Construir un pipeline ETL completamente automatizado, documentado y reproducible que transforme datos brutos de múltiples fuentes en un modelo dimensional almacenado en SQL, exportado a GitHub y analizado con PySpark en Google Colab para responder a preguntas de negocio definidas por el propio alumno.

2. Descripción de los Orígenes de Datos

Cada grupo debe documentar en su informe todas las fuentes de datos utilizadas.

Campo a documentar	Descripción / Ejemplo
Nombre de la fuente	Nombre identificativo (ej. "Transacciones Spotify API")
URL / Ruta de acceso	Ruta local, URL de API o enlace a dataset público (Kaggle, datos.gob.es…)
Formato	CSV, JSON, Excel, API REST, SQL dump, Parquet…
Nº de registros originales	Conteo exacto antes de cualquier transformación
Nº de variables originales	Número de columnas en la fuente cruda
Descripción de variables	Listado de campos con tipo de dato original y descripción de negocio
Frecuencia de actualización	Estática / Diaria / Tiempo real
Licencia / condiciones de uso	Open Data, API key requerida, datos simulados…
Enlace a documentación	URL de referencia oficial o ficha de metadatos

IMPORTANTE: Los ficheros originales (sin modificar) deben incluirse en data/raw/ del repositorio GitHub. Si los datos son privados o muy voluminosos, se incluirá una muestra de 500 registros y se documentará el procedimiento de acceso completo.

3. Diagrama de Flujo del Pipeline

El documento entregable debe incluir un diagrama de flujo que represente visualmente todas las etapas del pipeline, las fuentes de entrada, las transformaciones aplicadas y los artefactos de salida.

Arquitectura de referencia

Figura 1. Arquitectura de referencia del pipeline ETL completo.

REQUISITO: El alumno debe reproducir este diagrama adaptado a su caso específico (herramientas elegidas, nombre real de las fuentes, motor SQL elegido) e incluirlo en el documento entregable como Figura 1. Se recomienda usar ppt, draw.io, Lucidchart o similar.

4. Análisis Inicial de los Orígenes — Perfil de Calidad

Antes de aplicar ninguna transformación, el alumno debe realizar un análisis de calidad exhaustivo de cada fuente. Este análisis es la línea base que justifica todas las decisiones de limpieza posteriores.

4.1 Métricas obligatorias por fuente

Métrica	Descripción técnica	Herramienta Python
Número de registros	df.shape[0] — total de filas antes de cualquier filtro	pandas: df.shape
Número de variables	df.shape[1] — total de columnas en la fuente cruda	pandas: df.shape
Tipos de dato originales	Tipo inferido por pandas por columna (int64, object, float64…)	df.dtypes / df.info()
Conteo de nulos	Nulos por columna (NaN, None, NaT)	df.isnull().sum()
Conteo de blancos	Cadenas vacías "" o que solo contienen espacios	df.apply(lambda c: (c.str.strip()=="").sum())
Conteo de duplicados	Filas completamente duplicadas y duplicados por clave primaria	df.duplicated().sum()
Análisis de outliers	Variables numéricas: IQR, z-score, boxplot visual	scipy.stats.zscore / df.describe()
Rangos y valores únicos	Min, max, media, desv. típ. en numéricas; cardinalidad en categóricas	df.describe() / df.nunique()
Formatos de campo	Fechas mal formateadas, monedas con símbolo, códigos postales…	df[col].str.contains(pattern)
Consistencia referencial	Claves foráneas que no tienen correspondencia entre fuentes	pd.merge con indicator=True

4.2 Tabla resumen de calidad (plantilla a cumplimentar por el alumno)

Fuente	Registros	Variables	Nulos (%)	Blancos (%)	Duplicados	Outliers detect.
F1 — [nombre]						
F2 — [nombre]						
F3 — [nombre]						
TOTAL / MEDIA						

NOTA: Esta tabla debe completarse con los valores reales obtenidos de vuestro análisis.
El código Python que genera estas métricas debe estar documentado en el notebook.

5. Extracción, Transformación y Limpieza (ETL)

El pipeline ETL debe estar completamente implementado en Python y organizado en módulos independientes. Cada módulo corresponde a una fase y debe actualizar el fichero de tracking al finalizar su ejecución.

5.1 Fase EXTRACT — Extracción de Fuentes

- Lectura de fuentes en formatos distintos (CSV, JSON/API, Excel, SQL, log…)
- Manejo de errores de conexión/lectura (try/except con logging del error)
- Registro automático de la cantidad de registros leídos por fuente
- Almacenamiento de las fuentes crudas sin modificar en data/raw/

5.2 Fase TRANSFORM — Transformaciones obligatorias (T01–T10)

#	Transformación	Acción requerida	Tracking
T01	Eliminación de duplicados	drop_duplicates() por clave primaria + duplicados exactos	n eliminados + criterio
T02	Tratamiento de nulos	Estrategia por columna: imputar media/moda, forward-fill o descartar	n nulos por col. + estrategia
T03	Eliminación de blancos	Columnas de texto: strip() y reemplazar "" por NaN antes de T02	n blancos corregidos
T04	Corrección de tipos	Convertir a int, float, datetime, category según semántica de negocio	n cols. recasteadas
T05	Normalización de fechas	Formato ISO-8601: YYYY-MM-DD HH:MM: SS, timezone UTC	n fechas corregidas
T06	Normalización de texto	Minúsculas, eliminación de acentos/caracteres especiales donde aplique	n campos normalizados
T07	Corrección de rangos	Validar rangos de negocio (importes > 0, edades 0-120…)	n outliers filtrados + criterio
T08	Detección y gestión de outliers	IQR o z-score en numéricas; documentar si se eliminan o acota	n outliers + método usado
T09	Seudonimización de PII	Hash SHA-256 sobre campos con datos personales	n campos seudonimizados
T10	Validación referencial	Registros huérfanos: documentar, no eliminar automáticamente	n huérfanos por relación

5.3 Tabla resumen de Tracking del Pipeline (a cumplimentar)

Fase	Fuente	Registros entrada	Registros salida	Descartados	Motivo principal
EXTRACT	F1			—	—

EXTRACT	F2			—	—
T01 Duplicados	F1+F2+F3				
T02 Nulos	Dataset unif.				
T07 Rangos	Dataset unif.				
T08 Outliers	Dataset unif.				
MERGE final	Todas				

CALIDAD MÍNIMA EXIGIDA: tasa de nulos < 2% en campos críticos; 0 duplicados en clave primaria; todos los tipos de dato correctamente casteados; rango de fechas coherente con el dominio de negocio.

6. Análisis Exploratorio de Datos (EDA) Final

Una vez obtenido el dataset limpio y transformado, se realizará un EDA completo que permita entender la distribución, relaciones y patrones de los datos antes de cargarlos en el modelo dimensional.

6.1 Clasificación de variables

Tipo de variable	Subtipo	Ejemplos típicos	Estadísticos a reportar
Cuantitativa continua	Ratio / Intervalo	Importe, duración, distancia	Media, mediana, desv. típ., min, max, Q1, Q3
Cuantitativa discreta	Conteo	Nº canciones, nº pedidos	Frecuencias, moda, rango intercuartílico
Cualitativa nominal	Categoría sin orden	País, categoría de producto	Conteo por categoría, top-N, proporción
Cualitativa ordinal	Categoría con orden	Valoración (1-5 estrellas)	Frecuencias, mediana ordinal
Temporal	Fecha / Datetime	Fecha de compra, timestamp	Distribución mensual/semanal, tendencia
Booleana / Binaria	Flag 0/1	Activo, pagado, verificado	Proporción True/False

6.2 Gráficas opcionales

#	Gráfica	Variables	Librería recomendada
G01	Heatmap de nulos / correlaciones	Todas las variables del dataset final	seaborn.heatmap
G02	Histogramas + curva KDE	Todas las variables continuas	seaborn.histplot
G03	Boxplots comparativos	Continuas vs. variable categórica clave	seaborn.boxplot

G04	Barras de frecuencias	Variables categóricas (top 15 valores)	matplotlib.bar
G05	Serie temporal	Volumen de registros a lo largo del tiempo	matplotlib.plot
G06	Scatter plot / pairplot	Pares de variables continuas relevantes	seaborn.pairplot
G07	Mapa de calor geográfico (opcional)	Si existe variable de geolocalización	folium / plotly
G08	Funnel de tracking	Registros por fase del pipeline	matplotlib.barh

IMPORTANTE: Cada gráfica debe ir acompañada de un párrafo de interpretación que explique qué información aporta al negocio. Las gráficas sin comentario no puntúan en la rúbrica.

7. Diseño del Diagrama en Estrella (Modelo Dimensional)

Los datos limpios deben modelarse siguiendo el esquema en estrella de Ralph Kimball: una tabla de hechos central rodeada de tablas de dimensiones que aportan el contexto descriptivo.

7.1 Principios del esquema en estrella

- Tabla de Hechos: contiene las métricas numéricas del negocio y las claves foráneas a las dimensiones. Granularidad: un registro por evento de negocio.
- Tablas de Dimensiones: contienen atributos descriptivos (quién, qué, cuándo, dónde, cómo).
- Claves sustitutas (SK): nunca usar claves naturales como PK del DW. Usar SERIAL/AUTOINCREMENT.
- DIM_TIEMPO: sugerida. Descomposición en año, trimestre, mes, semana, día de la semana, festivo.

7.2 Esquema de referencia (adaptar al dominio de cada grupo)

Ejemplo 1.

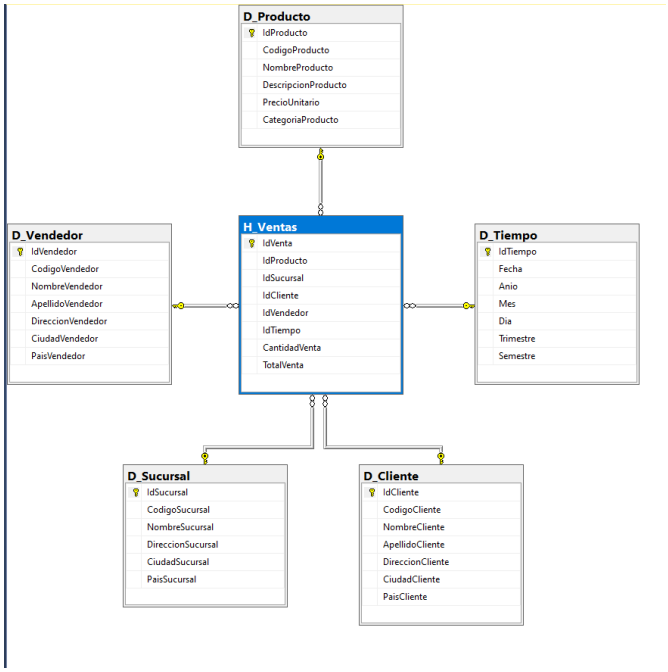

Ejemplo 2.

	DIM_TIEMPO sk_tiempo (PK) fecha DATE anio SMALLINT trimestre SMALLINT mes SMALLINT semana SMALLINT dia_semana VARCHAR es_festivo BOOLEAN	
DIM_USUARIO sk_usuario (PK) user_id_hash VARCHAR(64) pais VARCHAR(50) ciudad VARCHAR(50) plan_suscripcion segmento VARCHAR(30) fecha_alta DATE	**FACT_EVENTOS** sk_evento BIGINT (PK) FK sk_tiempo FK sk_usuario FK sk_producto FK sk_canal —— MEDIDAS —— importe DECIMAL(12,2) duracion_seg INTEGER cantidad INTEGER puntuacion DECIMAL flag_completado —— TRAZABILIDAD —— source_id VARCHAR load_timestamp TS	**DIM_PRODUCTO** sk_producto (PK) producto_id VARCHAR nombre VARCHAR(100) categoria VARCHAR(50) subcategoria VARCHAR proveedor VARCHAR(50)
	DIM_CANAL sk_canal (PK) canal VARCHAR(30) plataforma VARCHAR(30) dispositivo VARCHAR(30)	

Figura 2. Esquema en estrella de referencia. Adaptar al dominio de negocio del grupo.

7.3 Requisitos del diseño dimensional

Requisito	Descripción
Mín. 1 tabla de hechos	Con al menos 3 medidas numéricas y 3 claves foráneas a dimensiones
Mín. 4 dimensiones	Obligatoria DIM_TIEMPO; las otras dependen del dominio de negocio
Claves sustitutas (SK)	Todas las PKs de dimensiones deben ser SK enteros, no claves naturales
Granularidad definida	El documento debe indicar explícitamente qué representa un registro de FACT
Campo source_id	Trazabilidad: indica de qué fuente original proviene cada registro
Campo load_timestamp	Fecha y hora de carga, generado automáticamente en el pipeline
Diagrama en el documento	Figura obligatoria en el informe: tablas con campos y tipos de dato

8. Carga en Base de Datos SQL

Una vez definido el esquema en estrella, el alumno debe crear la base de datos y cargar los datos desde Python. La elección del motor SQL es libre (PostgreSQL, MySQL, SQLite, SQL Server Express, MariaDB…).

8.1 Proceso de carga

1. Crear el esquema: CREATE TABLE para cada dimensión y para la tabla de hechos, respetando PK, FK y NOT NULL.
2. Poblar dimensiones primero: siempre antes que la tabla de hechos para respetar la integridad referencial.
3. Poblar FACT: usando los SK generados en el paso anterior.
4. Verificar la carga: SELECT COUNT(*) en cada tabla y comparar con el tracking.
5. Documentar en el informe: motor elegido, string de conexión (sin credenciales), filas cargadas por tabla.

9. Exportación a GitHub

Todo el trabajo debe estar subido en un repositorio GitHub con visibilidad pública. El enlace al repositorio es un entregable obligatorio.

A modo de ejemplo:

9.1 Estructura del repositorio

```
proyecto_etl_bigdata/
├── data/
│   ├── raw/          <- fuentes originales (o muestra de 500 registros)
│   ├── processed/    <- CSV intermedios por fase de transformación
│   └── final/        <- CSV finales de cada tabla del modelo estrella
│       ├── dim_tiempo.csv
│       ├── dim_usuario.csv
│       ├── dim_producto.csv
│       ├── dim_canal.csv
│       └── fact_eventos.csv
├── src/
│   ├── extract.py  clean.py  transform.py  load.py  tracker.py
├── notebooks/
│   ├── 01_eda_inicial.ipynb
│   ├── 02_etl_pipeline.ipynb
│   └── 03_pyspark_cubo_colab.ipynb   <- cuaderno PySpark
```

```
├── logs/
│   └── pipeline_tracking.json
├── informe/
│   └── informe_proyecto.pdf
├── README.md
├── requirements.txt
└── .gitignore    <- incluir: .env, *.db, __pycache__/
```

Los CSV de data/final/ son los datos de entrada para el cuaderno PySpark en Google Colab.
El cuaderno debe leerlos directamente desde su URL raw en GitHub.

10. Cuaderno PySpark en Google Colab — Cubo Dimensional

El análisis final se realizará en Google Colab utilizando PySpark para simular un entorno de procesamiento distribuido. El cuaderno debe leer los CSV exportados a GitHub, construir el cubo dimensional y responder a las preguntas de negocio.

10.1 Configuración del entorno en Colab

```
# Celda 1: Instalar PySpark
!pip install pyspark findspark -q

# Celda 2: Iniciar SparkSession
from pyspark.sql import SparkSession
spark = SparkSession.builder \
    .appName("CuboBigData") \
    .config("spark.driver.memory", "2g") \
    .getOrCreate()
spark.sparkContext.setLogLevel("WARN")

# Celda 3: Leer tablas desde GitHub
BASE = "https://raw.githubusercontent.com/[usuario]/[repo]/main/data/final/"
import pandas as pd
fact_pd  = pd.read_csv(BASE + "fact_eventos.csv")
dim_t_pd = pd.read_csv(BASE + "dim_tiempo.csv")
fact     = spark.createDataFrame(fact_pd)
dim_t    = spark.createDataFrame(dim_t_pd)
```

10.2 Estructura mínima del cuaderno PySpark

Ver ejemplo en Canvas.

Sección	Contenido mínimo	Operaciones PySpark
1. Carga de datos	Lectura de CSV desde GitHub + conversión a Spark DataFrames	spark.createDataFrame(), printSchema(), show()

2. Registro de tablas	Registrar como vistas SQL temporales	createOrReplaceTempView()
3. Cubo dimensional	JOIN de FACT con dimensiones + agregaciones	join(), groupBy(), agg(), cube(), rollup()
4. Respuesta a preguntas	Mínimo 5 consultas analíticas	spark.sql(), filter(), orderBy(), window functions
5. Visualización	Exportar resultados a pandas y graficar	toPandas() + matplotlib/seaborn
6. Exportar gráficas	Guardar imágenes o descargar	plt.savefig() / files.download()

10.3 Preguntas de negocio — definición por el alumno

El alumno debe formular en el informe un mínimo de 3/5 preguntas de negocio que el cuaderno PySpark debe responder analíticamente. Estas preguntas deben:

- Estar relacionadas con el dominio de la empresa analizada en el Proyecto I
- Requerir el uso de al menos 2 dimensiones distintas en su respuesta
- Incluir al menos una pregunta con análisis temporal (usando DIM_TIEMPO)
- Incluir al menos una pregunta de tipo ranking (top-N)
- Estar respondidas por una consulta PySpark documentada y una gráfica

EJEMPLO de preguntas para empresa de streaming:
Q1 — ¿Cuál es la evolución mensual del número de escuchas en el último año?
Q2 — ¿Qué categoría musical genera mayor importe de suscripción por país?
Q3 — ¿Cuáles son los 10 artistas con mayor retención media de usuarios?
Q4 — ¿Qué dispositivo concentra mayor volumen de escuchas en fin de semana?
Q5 — ¿Existe correlación entre la duración media de sesión y la tasa de renovación?

11. Estructura del Documento Entregable

El entregable final es un documento PDF o Word que recoge toda la documentación técnica del proyecto. Debe seguir obligatoriamente la siguiente estructura. La ausencia de cualquier sección implica penalización en la rúbrica.

#	Sección obligatoria	Contenido mínimo esperado
0	Portada	Título, empresa, integrantes del grupo, asignatura, curso y fecha de entrega
—	Índice	Numerado con referencias de página. Índice de tablas e índice de figuras
1	Introducción	Contexto, empresa analizada, conexión con el Proyecto I y objetivo general
2	Orígenes y extracción	Documentación completa de cada fuente. Diagrama de flujo (Figura 1)
3	Análisis inicial de calidad	Tabla de calidad con valores reales. Capturas del código y outputs
4	ETL	Tabla de tracking completa. Justificación de cada decisión. Código documentado
5	EDA final	Clasificación de variables. Las 8 gráficas obligatorias con interpretación de negocio
6	Modelo dimensional	Diagrama en estrella (Figura 2 adaptada). Descripción de tablas. Granularidad
7	Carga SQL	Motor elegido y justificación. Código DDL. Tabla de verificación de registros
8	GitHub	URL del repositorio. Captura de la estructura de carpetas. Descripción del README
9	Cuaderno PySpark	URL del notebook. Las 5 preguntas con su consulta PySpark y gráfica de respuesta
10	Conclusiones	Reflexión sobre el valor del dataset. Dificultades encontradas y soluciones
11	Uso de IA y Bibliografía	Ver sección 14 de este documento

FORMATO: Fuente legible (mínimo 11pt), márgenes >= 2 cm, párrafos justificados.
Bloques de código en fuente monoespaciada. Extensión orientativa: 20-35 páginas sin contar anexos.

12. Rúbrica de Evaluación (10 puntos base × coeficiente de defensa)

La nota del proyecto se calcula en dos pasos: (1) puntuación técnica ponderada sobre 10 puntos y (2) multiplicación por el coeficiente de defensa oral (0.50 – 1.00).

NOTA FINAL = Puntuación técnica (0-10) × Coeficiente de defensa (0.50 – 1.00)
Ejemplo: puntuación técnica 8.5 × coeficiente 0.90 = 7.65 puntos finales

#	Criterio	Descripción y niveles de desempeño	Peso
C1	Estructura documental y ortografía	EXCELENTE: portada, índice, secciones numeradas, índice de tablas/figuras, sin errores. NOTABLE: falta algún elemento o 1-3 errores menores. APROBADO: estructura incompleta; 4-6 errores. SUSPENSO AUTOMÁTICO: más de 3 faltas graves o ausencia de portada/índice.	10%
C2	Diagrama de flujo del pipeline	EXCELENTE: diagrama propio adaptado al caso, todas las fases, fuentes y destinos, con leyenda. NOTABLE: diagrama completo, pero no adaptado a la empresa. APROBADO: diagrama parcial (faltan >= 2 fases). SUSPENSO: ausente o ilegible.	8%
C3	Procesos automatizados	EXCELENTE: pipeline ejecutable end-to-end; módulos separados por fase; manejo de errores; README funcional. NOTABLE: automatizado, pero con pasos manuales menores. APROBADO: funcional pero no modular. SUSPENSO: no ejecutable o sin organización.	10%
C4	Análisis inicial y EDA inicial	EXCELENTE: tabla de calidad completa (registros, variables, nulos, blancos, duplicados, outliers, rangos, formatos); gráficas de perfil; interpretación de cada hallazgo. NOTABLE: tabla completa, pero sin interpretación. APROBADO: tabla parcial (faltan >= 3 métricas). SUSPENSO: análisis ausente o con datos incorrectos.	12%
C5	ETL: extracción, transformación, limpieza y tracking	EXCELENTE: >=3 fuentes; las 10 transformaciones (T01-T10) aplicadas y justificadas; tracking completo con entrada/salida/motivo en CADA fase; calidad mínima alcanzada. NOTABLE: >=3 fuentes, >=7 transformaciones, tracking en >=4 fases. APROBADO: >=2 fuentes, >=5 transformaciones, tracking parcial. SUSPENSO: sin tracking, <2 fuentes o transformaciones insuficientes.	20%
C6	EDA final y clasificación de variables	EXCELENTE: todas las variables clasificadas; las 8 gráficas con interpretación >=3 líneas; conclusiones del EDA. NOTABLE: >=6 gráficas con interpretación. APROBADO: >=4 gráficas sin interpretación. SUSPENSO: <4 gráficas o sin clasificación de variables.	10%
C7	Diagrama en estrella	EXCELENTE: >=1 tabla de hechos y >=4 dimensiones, DIM_TIEMPO obligatoria, SK en todas las PK, granularidad definida, integrado en el documento. NOTABLE: correcto, pero sin SK o sin DIM_TIEMPO. APROBADO: esquema parcial (1 FACT + 2 DIM). SUSPENSO: ausente, incorrecto o con claves naturales como PK.	12%
C8	Carga en base de datos SQL	EXCELENTE: DDL explícito (PK, FK, NOT NULL); carga correcta desde Python; verificación con COUNT(*); motor documentado; 0	10%

		credenciales expuestas. NOTABLE: carga correcta, pero sin DDL o sin verificación. APROBADO: carga funcional con errores menores. SUSPENSO: no cargada o con errores graves.	
C9	Enlace a GitHub (exportación CSV)	EXCELENTE: repositorio público accesible, estructura completa, CSV de todas las tablas en data/final/, README funcional, gitignore correcto, sin credenciales. NOTABLE: completo, pero README incompleto. APROBADO: estructura parcial o CSV incompletos. SUSPENSO: enlace roto, privado sin acceso o sin CSV.	8%
C10	Cuaderno PySpark (Google Colab)	EXCELENTE: ejecutable sin errores; lee desde GitHub; JOIN correcto; >=5 consultas analíticas; >=5 gráficas exportadas; preguntas respondidas con conclusión. NOTABLE: >=4 consultas con >=3 gráficas. APROBADO: funcional con >=2 consultas. SUSPENSO: no ejecutable, sin PySpark o sin respuesta a preguntas.	10%

FÓRMULA: C1×0.10 + C2×0.08 + C3×0.10 + C4×0.12 + C5×0.20 + C6×0.10 + C7×0.12 + C8×0.10 + C9×0.08 + C10×0.10

(cada criterio Ci se puntúa de 0 a 10)

13. Defensa Oral y Coeficiente de Calificación

La defensa oral es obligatoria y actúa como multiplicador de la puntuación técnica. Ningún grupo puede aprobar el proyecto sin realizar la defensa.

13.1 Material de apoyo

El alumno puede apoyarse en cualquier material audiovisual durante la defensa. La única restricción es que la duración total del material reproducido no supere los 5 minutos.

- Presentación PowerPoint / PDF: slides con capturas del código, gráficas del EDA, diagrama en estrella y tabla de tracking.
- Vídeo demostrativo: grabación de pantalla mostrando la ejecución del pipeline, la base de datos cargada y el cuaderno Colab (máx. 5 min).
- Notebook en vivo: ejecución en directo del cuaderno PySpark si el tiempo lo permite.
- Dashboard interactivo: si se ha desarrollado como bonus.

13.2 Estructura recomendada de la defensa (15 min total)

Bloque	Contenido	Duración
1. Material de apoyo	Reproducción de vídeo/presentación preparada	Máx. 5 min
2. Demo técnica	Mostrar código ejecutado, base de datos y Colab	3-4 min
3. Reflexión	Qué aprendisteis, dificultades y valor del dataset	2-3 min
4. Preguntas	El profesor formula preguntas a cualquier miembro del grupo	5-6 min

13.3 Coeficiente de defensa oral

Coeficiente	Nivel	Criterios observados
1.00	Excelente	Todos los miembros participan; responden con seguridad preguntas técnicas; demuestran comprensión profunda; material de apoyo claro y profesional.
0.90	Notable	Participación equitativa; responden correctamente la mayoría de preguntas; material adecuado.
0.75	Bien	Algún miembro no participa; respuestas correctas pero superficiales; material básico.
0.60	Suficiente	Participación desequilibrada; dificultad para responder preguntas técnicas; material escaso.
0.50	Defensa muy débil	Solo habla un miembro; no responden preguntas; no demuestran haber realizado el trabajo por sí mismos.

CÁLCULO FINAL ILUSTRATIVO: Grupo con puntuación técnica 9.0 y coeficiente de defensa 0.75 → Nota final = 9.0 × 0.75 = 6.75. El coeficiente penaliza la falta de conocimiento real del trabajo.

14. Uso de Inteligencia Artificial y Bibliografía

El uso de herramientas de Inteligencia Artificial (ChatGPT, Claude, Copilot, Gemini, etc.) está permitido en este proyecto, siempre que se declare de forma transparente. El uso no declarado se considerará deshonestidad académica.

14.1 Declaración de uso de IA

El documento entregable debe incluir una sección final titulada "Uso de Inteligencia Artificial" con la siguiente información por cada herramienta empleada:

Campo a declarar	Ejemplo
Herramienta utilizada	Claude 3.5 Sonnet (Anthropic)
Tarea en la que se empleó	Generación de código base para el módulo tracker.py
Grado de modificación	Alto — el código se modificó sustancialmente para adaptarlo al dominio
Verificación realizada	El alumno ejecutó y validó cada bloque generado
Prompts utilizados (resumen)	"Escribe una clase Python para registrar tracking de registros ETL en JSON"

CRITERIO: No se penaliza el uso de IA. Sí se penaliza no declararlo, o presentar código generado por IA que el alumno no sabe explicar. La defensa oral detectará este segundo caso.

14.2 Referencias bibliográficas y recursos

- Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit, 3rd ed. Wiley.
- pandas Documentation — https://pandas.pydata.org/docs/
- PySpark Documentation — https://spark.apache.org/docs/latest/api/python/
- SQLAlchemy Documentation — https://docs.sqlalchemy.org/
- RGPD — https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32016R0679
- Datasets públicos utilizados: Kaggle, datos.gob.es, UCI ML Repository…
- Vídeos o tutoriales consultados (autor, título, URL y fecha de acceso)